

Laporan Akhir CSKG from Unstructured Data

Kelompok 7

MII212503 Metode Rekayasa Perangkat Lunak KOMB

Nama Kelompok : Mie Ayam Palembang Afui

PIC : Axelle Chandra (24/533796/PA/22614)

Anggota Kelompok:

1. Keyne Elvaretta Zulfa Arafah (24/533391/PA/22572)
2. Kesya Izumi (24/533729/PA/22612)
3. Danar Fathurahman (24/538200/PA/22828)

Link GitHub : github.com/.../cskg-from-unstructure-kelompok-7

Daftar Isi

1	Ringkasan Proyek	2
2	Latar Belakang dan Tujuan	2
3	Arsitektur / Metode	3
4	Implementasi	4
4.1	Data Sources	4
4.2	Ontology	5
4.3	SEPSES Linking	6
5	Hasil Evaluasi dan Demo	7
5.1	Evaluasi Statistik Graph	7
5.2	Demo Use-Case SPARQL	9
5.3	Ringkasan Hasil Use-Case	9
5.4	Analisis Hasil Evaluasi	9
6	Kendala dan Limitasi	10
7	Kontribusi Anggota	10
8	Kesimpulan	11

1. Ringkasan Proyek

Proyek ini membangun *Cybersecurity Knowledge Graph* (CSKG) dari data cybersecurity tidak terstruktur seperti RSS feed, threat research, vendor alert, dan NVD API. Pipeline mengambil data, mengekstrak entitas serta relasi menggunakan Gemini/LangChain, mengubah hasil ekstraksi menjadi RDF triples berbasis STIX-style ontology, lalu menyimpannya ke Virtuoso agar dapat diakses melalui FastAPI dan SPARQL.

Pada *final runtime snapshot*, graph pada named graph <http://group2.org/cskg> berisi **1009 triples**, 94 reports, 30 vulnerabilities, 25 malware, 11 indicators, 85 attack patterns, 60 threat actors, dan 11 SEPSES CVE URIs. Proyek ini juga menyediakan tiga use-case SPARQL untuk statistik graph, SEPSES CVE linking, dan analisis konteks attack pattern/malware.

2. Latar Belakang dan Tujuan

Informasi cybersecurity umumnya tersebar dalam berbagai sumber seperti artikel berita, blog keamanan, vendor alert, threat research, dan database vulnerability. Informasi tersebut sering kali berbentuk teks tidak terstruktur, sehingga sulit dianalisis secara langsung oleh sistem. Di dalam satu artikel, misalnya, dapat terdapat banyak informasi penting seperti nama malware, CVE, threat actor, teknik serangan, indikator kompromi, dan produk yang terdampak. Namun, jika data tersebut hanya disimpan sebagai teks biasa, hubungan antar entitas menjadi sulit ditelusuri.

Cybersecurity Knowledge Graph (CSKG) digunakan untuk mengatasi masalah tersebut dengan merepresentasikan informasi cybersecurity sebagai graph. Dalam graph, entitas seperti threat actor, malware, vulnerability, indicator, attack pattern, dan report dapat dihubungkan melalui relasi tertentu, misalnya **uses**, **targets**, **exploits**, atau **mentions**. Dengan pendekatan ini, informasi yang sebelumnya tersebar dalam artikel dapat diubah menjadi data terstruktur yang dapat dicari, dianalisis, dan dihubungkan menggunakan query SPARQL.


Tujuan proyek ini adalah sebagai berikut:

1. Menjalankan dan mengembangkan pipeline awal untuk membangun CSKG dari data cybersecurity tidak terstruktur.
2. Menambahkan beberapa sumber data cybersecurity agar graph tidak hanya bergantung pada satu sumber.
3. Mengadopsi ontology cybersecurity berbasis STIX-style model serta menggunakan namespace CSKG dan SEPSES CVE URI.
4. Mengekstrak entitas dan relasi penting seperti threat actor, malware, vulnerability, indicator, attack pattern, dan report.
5. Menyimpan hasil ekstraksi dalam bentuk RDF triples pada Virtuoso named graph <http://group2.org/cskg>.
6. Menyediakan query SPARQL untuk mendemonstrasikan penggunaan graph dalam skenario nyata, seperti statistik graph, SEPSES CVE linking, dan analisis konteks attack pattern/malware.

7. Mengevaluasi hasil graph berdasarkan jumlah triples, distribusi entitas, hasil use-case query, kendala, dan limitation yang ditemukan selama pengerjaan.

3. Arsitektur / Metode

Arsitektur ini menunjukkan alur pembangunan CSKG dari data cybersecurity tidak terstruktur menjadi graph yang bisa dianalisis. Untuk alur lengkapnya dapat dilihat di gambar 1.



Gambar 1: Diagram arsitektur sistem

1) Data Sources

Data diambil dari dua sumber utama:

- **Cybersecurity RSS Feeds** — untuk mengambil artikel, berita, dan threat research.
- **NVD API** — untuk mengambil data CVE terbaru.

2) Ingestion

Data yang masuk diproses oleh Scraper melalui `pipeline/scraper.py`. Pada tahap ini, sistem melakukan:

- pengambilan data,

- pembersihan konten,
- deduplikasi URL melalui `seen_urls`,
- penyimpanan artikel siap proses ke `articles_queue`.

3) LLM Extraction

Artikel dari queue diproses oleh Extractor Worker melalui `pipeline/extractor_worker.py`. Konten artikel dikirim ke Gemini + LangChain untuk mengekstrak entitas dan relasi penting, seperti:

- threat actor, malware, CVE, IOC, attack pattern,
- relasi antar-entitas.

Hasil ekstraksi disimpan sebagai *Extracted Entity JSON*, lalu dikirim ke `extractions_queue`.

4) Knowledge Graph Build

Hasil ekstraksi diproses oleh Graph Builder Worker dan RDF Mapper. Data JSON diubah menjadi RDF triples menggunakan STIX-style ontology, CSKG namespace, dan SEPSES CVE URI.

5) Graph Storage

RDF triples disimpan ke Virtuoso RDF Store dalam named graph `http://group2.org/cskg`. Data graph juga disimpan secara persisten melalui volume `virtuoso_db`.

6) Access and Output

Graph dapat diakses melalui FastAPI Service (`server/api_server.py`) dengan endpoint:

- GET / — status service,
- GET /stats — statistik graph,
- POST /query — menjalankan query SPARQL.

Sistem juga menghasilkan Daily Brief Reports (`pipeline/graph_eval_worker.py`) dan file export Turtle `cskg_full_dump.ttl` (`server/cskg_dump.py`).

4. Implementasi

Implementasi terdiri dari tiga komponen utama: data sources, ontology, dan SEPSES linking.

4.1. Data Sources

Pipeline mengambil data dari beberapa sumber cybersecurity berbentuk RSS feed dan API.

Source	Informasi yang Diambil	Alasan Pemilihan
TheHackerNews	Berita cybersecurity, malware, vulnerability, threat actor	Cakupan berita keamanan yang luas; sering memuat CVE atau campaign terbaru
BleepingComputer	Incident report, ransomware, malware, CVE	Banyak memuat laporan teknis dan kasus serangan aktual
KrebsOnSecurity	Investigasi cybercrime, breach, threat actor	Cocok untuk menemukan konteks aktor dan aktivitas cybercrime
Securelist	Threat research, APT report, malware analysis	Menyediakan analisis teknis yang lebih mendalam
Check Point Research	Malware, exploit, campaign analysis	Menambah variasi sumber threat research
SANS ISC	Threat monitoring, alert, indicator	Berguna untuk observasi ancaman dan indikator serangan
FortiGuard Labs	Vendor alert, outbreak report, CVE, mitigation	Menyediakan informasi vulnerability dan outbreak dari vendor security
NVD API	CVE, vulnerability description, published date	Sumber vulnerability terstruktur untuk memperkuat data CVE

Setiap data yang berhasil diambil disimpan dalam format JSON berisi judul, tautan sumber, tanggal publikasi, dan ringkasan konten, kemudian dimasukkan ke Redis queue. Alur data source secara sederhana:

RSS/API Sources → Scraper/Producer → Redis articles_queue → LLM
Extractor

4.2. Ontology

Proyek ini menggunakan pendekatan STIX-style ontology. STIX (*Structured Threat Information Expression*) adalah standar yang umum digunakan dalam cyber threat intelligence untuk mendeskripsikan entitas dan relasi keamanan siber.

Namespace utama:

Prefix	URI	Fungsi
stix	http://docs.oasis-open.org/cti/ns/stix/	Namespace utama class dan relasi cybersecurity
cskg	http://group2.org/cskg/	Namespace custom untuk entitas lokal
sepses	https://w3id.org/sepses/resource/cve/	Namespace eksternal untuk linking CVE
rdfs	http://www.w3.org/2000/01/rdf-schema#	Label entitas
dcterms	http://purl.org/dc/terms/	Metadata (tanggal publikasi)

Entity Class	Fungsi
stix:Report	Artikel atau laporan sumber
stix:ThreatActor	Aktor ancaman (APT, hacker group, attacker)
stix:Malware	Malware, ransomware, botnet, trojan, malicious tool
stix:Vulnerability	Vulnerability, terutama CVE
stix:Indicator	Indikator kompromi (IP, domain, hash, URL)
stix:AttackPattern	Teknik atau pola serangan

Entity class utama:

Relasi antar entitas:

Predicate	Makna
stix:mentions	Report menyebutkan suatu entitas
stix:uses	Threat actor/malware menggunakan tool/teknik tertentu
stix:targets	Entitas menyerang atau menargetkan entitas lain
stix:exploits	Threat actor/malware mengeksploitasi vulnerability
stix:patched	Vulnerability telah diperbaiki
stix:variant_of	Malware merupakan varian dari malware lain
stix:reports	Entitas atau report melaporkan objek tertentu
rdfs:label	Nama yang dapat dibaca manusia
dcterms:created	Tanggal publikasi atau waktu pembuatan report

Contoh representasi triple dalam graph:

```
<https://example.com/security-report>
  a stix:Report ;
  stix:mentions cskg:lockbit ;
  stix:mentions <https://w3id.org/sepses/resource/cve/CVE-2025-52691> .

cskg:lockbit
  a stix:Malware ;
  rdfs:label "LockBit" .
```

Listing 1: Contoh RDF triple – Report dan Malware

4.3. SEPSES Linking

Salah satu requirement utama proyek ini adalah melakukan linking antara constructed graph dengan entitas yang sudah ada pada SEPSES CSKG, difokuskan pada CVE-to-SEPSES URI mapping.

Apabila extractor mengidentifikasi vulnerability dengan format CVE, sistem secara otomatis mengadopsi URI SEPSES CVE resmi:

<https://w3id.org/sepses/resource/cve/CVE-XXXX-XXXXX>

Ringkasan mapping yang diterapkan:

Extracted Entity	Graph URI
CVE-2025-52691	https://w3id.org/sepsese/resource/cve/CVE-2025-52691
CVE-2026-0257	https://w3id.org/sepsese/resource/cve/CVE-2026-0257

```

<https://w3id.org/sepsese/resource/cve/CVE-2025-52691>
  a stix:Vulnerability ;
  rdfs:label "CVE-2025-52691" .

<https://fortiguard.fortinet.com/outbreak-alert/smartertools-smartermail-rce>
  a stix:Report ;
  stix:mentions <https://w3id.org/sepsese/resource/cve/CVE-2025-52691> .

```

Listing 2: Contoh triple SEPSES CVE linking

Pada final runtime snapshot, graph telah menampung **11 SEPSES CVE URIs**. Scope SEPSES linking saat ini masih terbatas pada CVE URI mapping; alignment terhadap teknik CWE dan MITRE ATT&CK dicatat sebagai *future work*.

5. Hasil Evaluasi dan Demo

Data utama dikelola pada named graph <http://group2.org/cskg>.

Statistik final runtime snapshot:

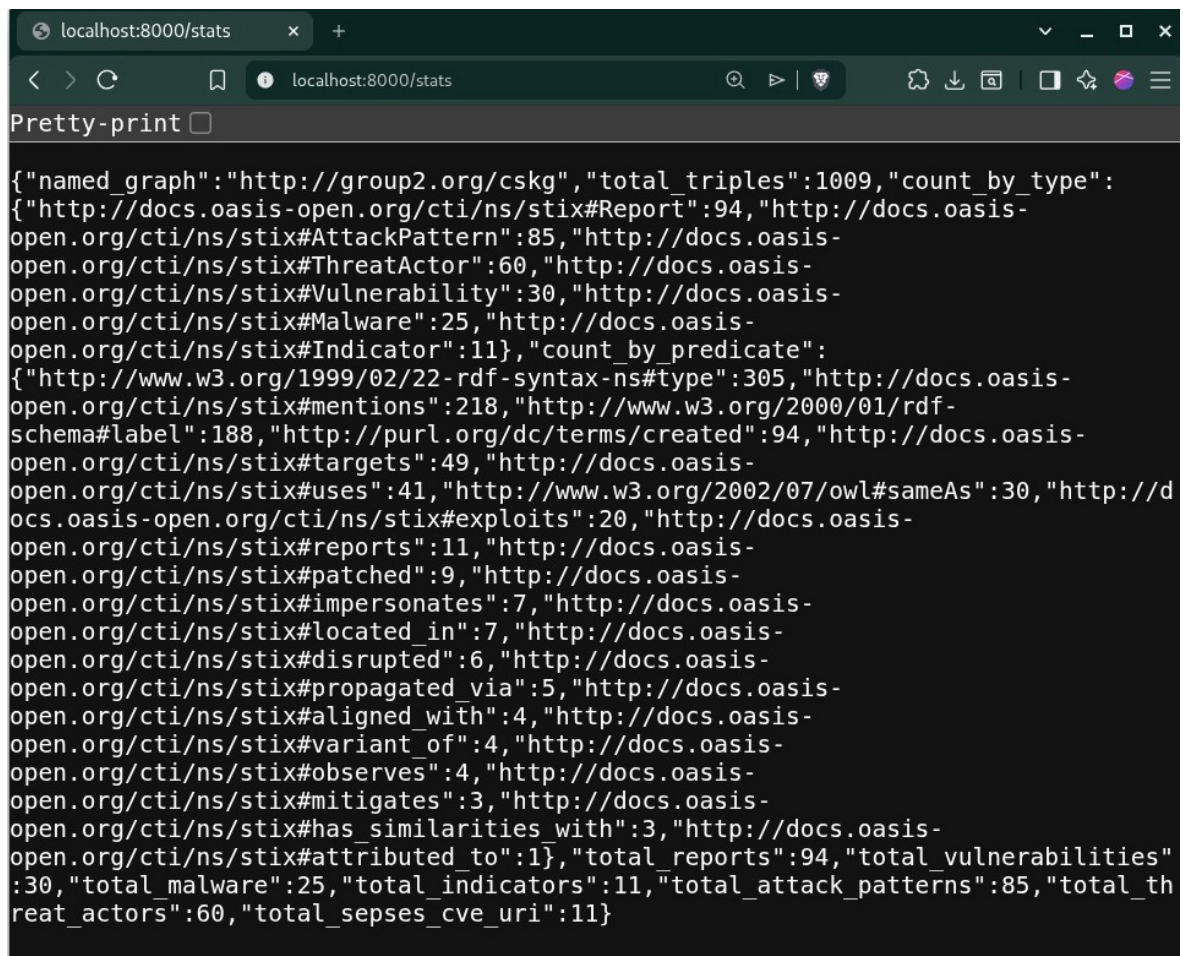
Metric	Value
CSKG named graph triples	1009
Reports	94
Vulnerabilities	30
Malware	25
Indicators	11
Attack patterns	85
Threat actors	60
SEPSSES CVE URIs	11

Tabel 2: Distribusi entitas pada final runtime snapshot


5.1. Evaluasi Statistik Graph

Data statistik graph diakses melalui endpoint `GET /stats`. Layanan ini menghitung jumlah entitas berdasarkan tipe STIX pada named graph CSKG, sehingga tidak tercampur dengan global triples yang tersimpan di Virtuoso. Untuk screenshot dapat dilihat pada gambar 2

Entitas dengan volume terbesar adalah 85 AttackPattern, 60 ThreatActor, dan 94 Report. Distribusi ini merepresentasikan kapabilitas graph dalam mengekstrak konteks teknis serangan serta profil aktor ancaman dari berbagai sumber data.



Gambar 2: Endpoint GET /stats menunjukkan distribusi entity pada final runtime snapshot.



Gambar 3: Endpoint GET / menunjukkan status API, backend Virtuoso, named graph, dan jumlah triples pada CSKG named graph.

5.2. Demo Use-Case SPARQL

Proyek menyediakan tiga use-case SPARQL, seluruhnya dieksekusi terhadap named graph GRAPH <<http://group2.org/cskg>>.

Use Case 1 — KG Statistics

Use-case ini menampilkan ringkasan statistik graph, meliputi total triples dan distribusi entity berdasarkan tipe.

Use Case	Rows
KG Statistics	7

Hasil mencakup 1009 total_triples, 85 AttackPattern, dan 11 Indicator.

Use Case 2 — SEPSES CVE Linking

Use-case ini menelusuri vulnerability yang terintegrasi melalui mekanisme SEPSES CVE linking, mengidentifikasi CVE yang telah dipetakan ke URL resmi

<https://w3id.org/sepses/resource/cve/>.

Use Case	Rows
SEPSSES CVE Linking	13

Data hasil query mencakup CVE-2025-34291, CVE-2025-52691, dan CVE-2026-0257, di mana masing-masing entitas terhubung secara akurat dengan URL report sumbernya.

Use Case 3 — Attack Pattern / Malware Context

Use-case ini memetakan hubungan timbal balik antara attack pattern, malware, dan report untuk memfasilitasi identifikasi taktik serangan dalam laporan.

Use Case	Rows
Attack Pattern / Malware Context	241

Beberapa entitas yang teridentifikasi mencakup *AI-generated lures*, *Abuse of administration features*, dan *Abuse of legitimate applications*.

5.3. Ringkasan Hasil Use-Case

5.4. Analisis Hasil Evaluasi

Pipeline dinilai berhasil karena seluruh alur kerja beroperasi secara end-to-end: data berhasil diakuisisi dari berbagai sumber, diekstraksi melalui engine LLM, ditransformasikan menjadi RDF triples, dipersistensikan ke Virtuoso, dan dapat diakses kembali via FastAPI serta query SPARQL.

Integrasi 11 SEPSES CVE URIs mengonfirmasi keberhasilan pemetaan vulnerability ke namespace eksternal, membuka peluang interkoneksi dengan knowledge graph keamanan

Use Case	Tujuan	Rows	Status
KG Statistics	Ringkasan statistik dan distribusi entity graph	7	Berhasil
SEPSES CVE Linking	Menelusuri CVE terhubung ke SEPSES URI dan report sumber	13	Berhasil
Attack Pattern / Malware Context	Menelusuri konteks attack pattern, malware, dan report	241	Berhasil

Tabel 3: Ringkasan hasil tiga use-case SPARQL

siber berskala global. Namun, evaluasi ini memiliki batasan: volume data masih dipengaruhi kapasitas batch dan kualitas output model Gemini; penyelarasan terhadap CWE dan MITRE ATT&CK diproyeksikan sebagai *future work*.

6. Kendala dan Limitasi

1. **Sifat akumulatif graph.** Volume triples terus tereskalasi selama komponen producer, extractor, dan graph builder aktif. Analisis dalam laporan ini didasarkan pada final runtime snapshot (1009 triples).
2. **Ketergantungan pada kualitas sumber data.** Beberapa RSS feed hanya menyediakan ringkasan terbatas, sehingga proses ekstraksi LLM tidak selalu mencapai kelengkapan optimal.
3. **Limitasi engine Gemini/LangChain.** Terdapat potensi variasi nama untuk entitas yang sama, anomali klasifikasi, serta deteksi relasi yang belum sempurna. Peningkatan kualitas di masa depan memerlukan normalisasi, validasi manual, dan *entity disambiguation*.
4. **Scope SEPSES linking.** Saat ini difokuskan pada CVE-to-SEPSES URI mapping (11 URIs terverifikasi). Penyelarasan terhadap CWE dan MITRE ATT&CK dicatat sebagai *future work*.
5. **Keterbatasan evaluasi formal.** Parameter precision dan recall belum dapat dikalkulasi secara formal akibat ketiadaan gold-standard dataset. Penilaian bertumpu pada indikator runtime evidence, statistik graph, dan validasi fungsional use-case SPARQL.

Secara keseluruhan, kendala tersebut tidak mengganggu fungsionalitas inti sistem. Pipeline tetap beroperasi efektif dari akuisisi data hingga penyediaan akses melalui FastAPI dan SPARQL.

7. Kontribusi Anggota

Anggota	Kontribusi
Axelle Chandra	Mengkoordinasikan pengerjaan issue dan progress kelompok, membantu penyusunan README dan dokumentasi, menyiapkan use-case SPARQL, menyusun laporan akhir, slide presentasi, serta melakukan pengecekan konsistensi final documentation.
Danar Fathurahman	Melakukan runtime verification, menjalankan dan memeriksa pipeline Docker/Compose, Virtuoso, Redis, dan FastAPI. Membantu validasi endpoint <code>/</code> , <code>/stats</code> , <code>/query</code> , pengecekan graph builder, TTL dump, serta evidence untuk demo sistem.
Keyne Elvaretta	Berfokus pada dokumentasi dan perluasan data sources. Menjelaskan sumber data yang digunakan, alasan pemilihan source, jenis informasi yang diambil, serta kontribusi source terhadap pembentukan CSKG.
Kesya Izumi	Berfokus pada dokumentasi ontology dan SEPSES linking. Menjelaskan STIX-style ontology, entity classes, predicates, custom CSKG namespace, serta batasan SEPSES linking yang saat ini difokuskan pada CVE-to-SEPSES URI mapping.

Selain pembagian tugas tersebut, seluruh anggota berperan dalam diskusi kelompok, pengecekan issue GitHub, review hasil implementasi, dan persiapan presentasi akhir.

8. Kesimpulan

Proyek ini berhasil membangun pipeline CSKG dari data cybersecurity tidak terstruktur. Pipeline mampu mengambil data dari berbagai sumber RSS/API, memprosesnya melalui Redis queue, mengekstrak entitas dan relasi menggunakan Gemini/LangChain, mengubah hasil ekstraksi menjadi RDF triples berbasis STIX-style ontology, lalu menyimpannya ke Virtuoso pada named graph <http://group2.org/cskg>.

Pada final runtime snapshot, graph memiliki **1009 triples** terdiri dari 94 reports, 30 vulnerabilities, 25 malware, 11 indicators, 85 attack patterns, 60 threat actors, dan 11 SEPSES CVE URIs. Ketiga use-case SPARQL (KG Statistics, SEPSES CVE Linking, Attack Pattern/Malware Context) berhasil dijalankan dan menunjukkan bahwa graph dapat digunakan untuk analisis sederhana maupun penelusuran entitas secara semantik.

Secara keseluruhan, proyek ini telah memenuhi tahapan utama yang diminta, mulai dari penambahan data sources, penyusunan ontology, ekstraksi entitas dan relasi, pembuatan RDF triples, penyimpanan ke Virtuoso, penyediaan SPARQL endpoint, hingga evaluasi hasil graph. Ruang pengembangan masih terbuka pada perluasan coverage data, peningkatan kualitas entity disambiguation, serta alignment yang lebih lengkap ke SEPSES untuk CWE dan MITRE ATT&CK.

Dengan demikian, CSKG yang dibangun dapat menjadi dasar analisis cybersecurity berbasis graph dan dikembangkan lebih lanjut menjadi sistem threat intelligence yang lebih lengkap, akurat, dan terhubung dengan knowledge graph eksternal.